考虑驾驶风格的网联自主车辆换道意图预测方法

主线：为什么考虑风格 → 如何识别 → 如何预测 → 实验证据 → 方法边界

从轨迹差异到驾驶风格
再到三类换道意图预测

李文杰、曲大义、崔善柠、张智、韦良帅

山东理工大学学报（自然科学版）｜2026，40(2)：36—42

汇报人：_____　单位：_____　日期：_____

研究背景与问题

核心问题：相似的运动状态，是否需要结合驾驶风格理解其意图?

左换道

驶入左侧相邻车道

车道保持

继续沿当前车道行驶

右换道

驶入右侧相邻车道

三类意图识别

为车辆决策与轨迹规划提供参考

现有研究与本文思路

本文把“先划分风格，再预测意图”作为关键流程变化。

传统机器学习

SVM、HMM等
从观测特征推断行为类别

深度学习

LSTM、CNN等
学习轨迹及环境信息

轨迹数据

运动状态与统计特征

→

风格分类

保守／一般／激进

→

意图预测

左换道／保持／右换道

数据来源与预处理

从NGSIM历史轨迹中，筛选出852条换道与599条车道保持轨迹。

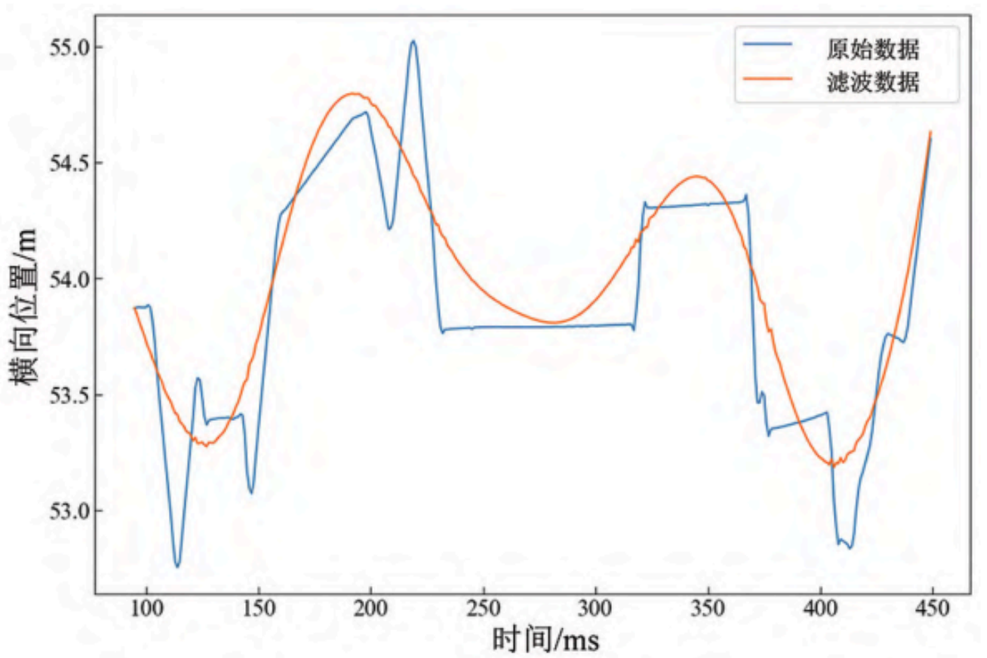
数据来源

US-101 + I-80
累计90 min

处理与筛选

小波分解降噪；仅保留小汽车
剔除停车、瞬时速度异常等轨迹

换道样本：换道前5 s + 换道后3 s



论文图1：滤波处理对比

来源：论文第1节；右图为论文图1

方法总体框架

驾驶风格类别先划分样本，再组织ConvLSTM的学习与验证。

训练与验证

轨迹筛选

NGSIM → 有效轨迹

→

特征分析

6项统计指标 → PCA

→

风格聚类

k-means，k = 3

各风格轨迹分组

保守型／一般型／激进型
每组按8：2划分训练与测试

→

意图预测

两层ConvLSTM → 全连接 → Softmax
输出三类意图概率

驾驶风格特征构建

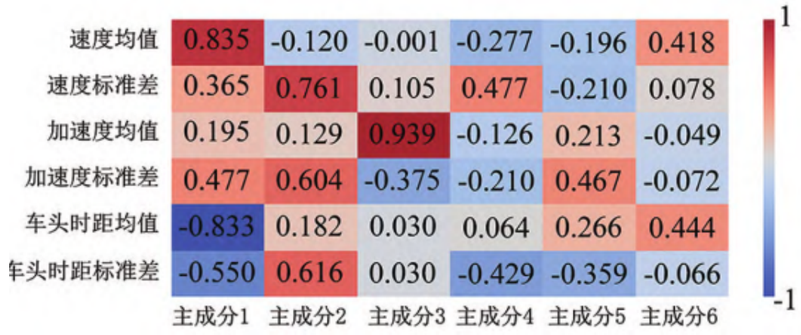
PCA分析后，论文选用速度均值、速度标准差、加速度均值进行聚类。

初始六项指标

速度：均值、标准差
加速度：均值、标准差
车头时距：均值、标准差

KMO = 0.624
巴特利特检验显著（p < 0.05）

主成分	特征值	累计贡献率
1	2.093	34.857%
2	1.688	62.971%
3	1.156	82.222%

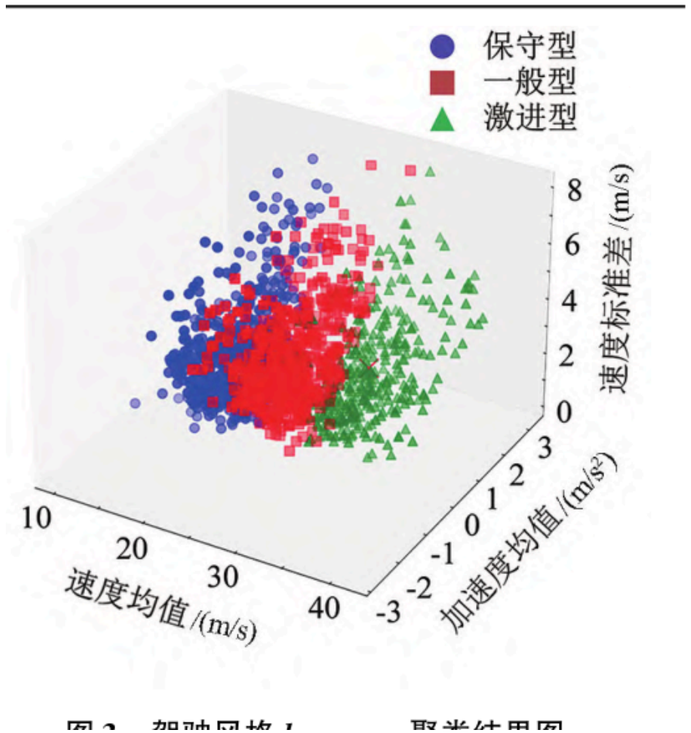


论文图2：主成分热力图；表4（精简）

来源：论文表2—5；右图为论文图2，右表精简自论文表4

k-means驾驶风格分类

预设k = 3；三类风格的速度均值、速度波动和平均加速度依次增大。



论文图3：驾驶风格聚类结果

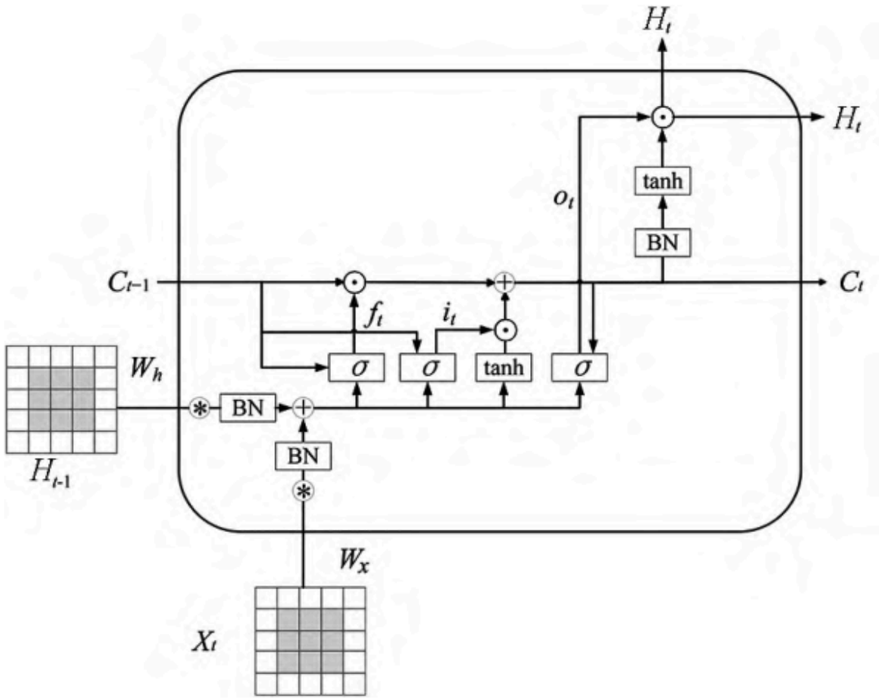
指标	保守型	一般型	激进型
样本数	535	582	334
速度均值 / m・s⁻¹	25.289	32.155	37.091
速度标准差 / m・s⁻¹	2.891	3.327	4.353
加速度均值 / m・s⁻²	0.113	0.175	0.372

三类名称是对聚类结果的行为解释。

来源：论文图3、表6（精简）

ConvLSTM为何用于意图预测

在LSTM门控中引入卷积，联合处理时间变化与空间特征。



论文图4：ConvLSTM单元

输入门

控制新信息写入

遗忘门

控制历史信息保留

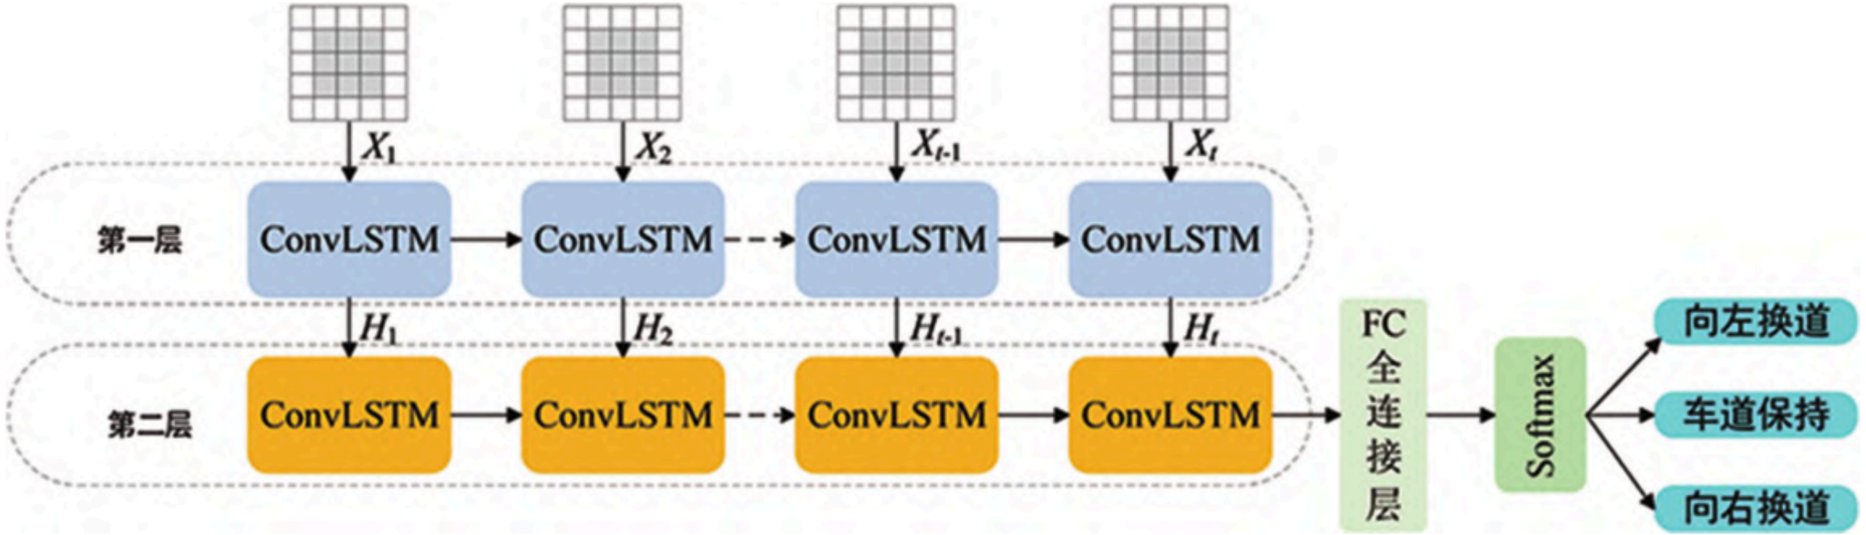
输出门

控制当前状态输出

来源：论文第3.1节；左图为论文图4

换道意图预测模型

两层ConvLSTM提取序列特征，Softmax输出三类意图概率。



论文图5：ConvLSTM车辆换道意图预测模型

优化器	学习率	Dropout	批次
Adam	0.01	0.2	128

来源：论文图5；参数精简自论文表7

实验设计与评价指标

通过风格分组验证与基线对照，分别观察风格差异和整体方法收益。

风格分组验证

保守型／一般型／激进型
各组按8：2划分训练集与测试集
统一使用ConvLSTM预测

四种模型对照

CNN*、LSTM*、ConvLSTM*
与考虑风格的ConvLSTM比较
重点：同一网络有无风格划分

准确率

整体分类正确程度

精确率／召回率

各意图类别的识别表现

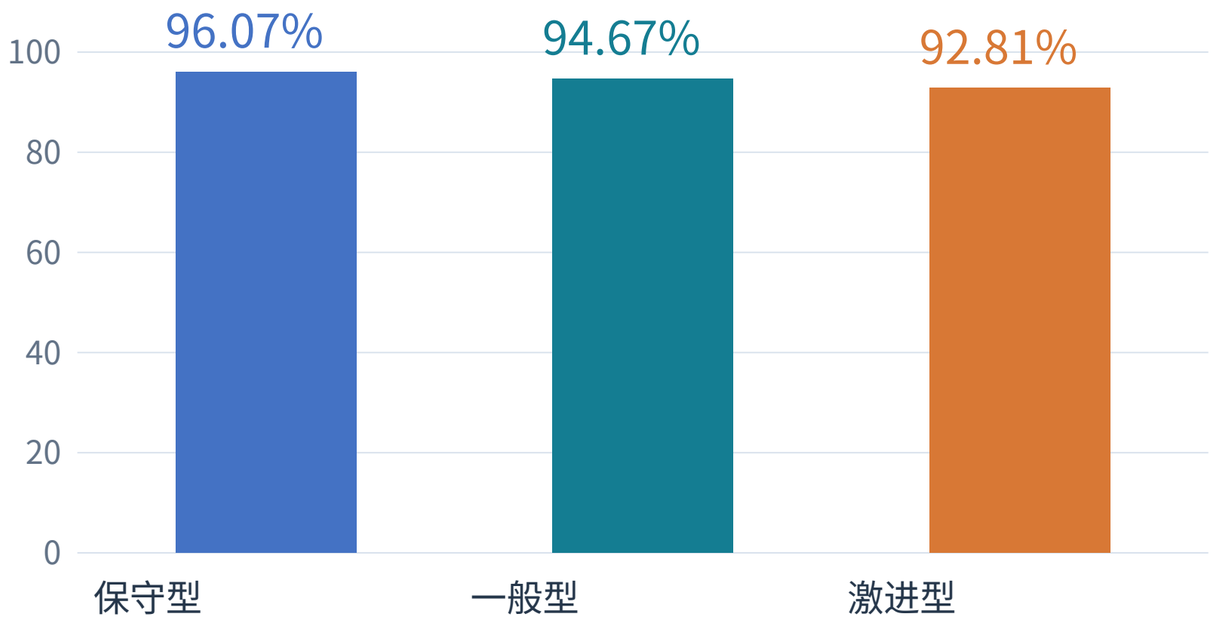
混淆矩阵

真实与预测类别的对应

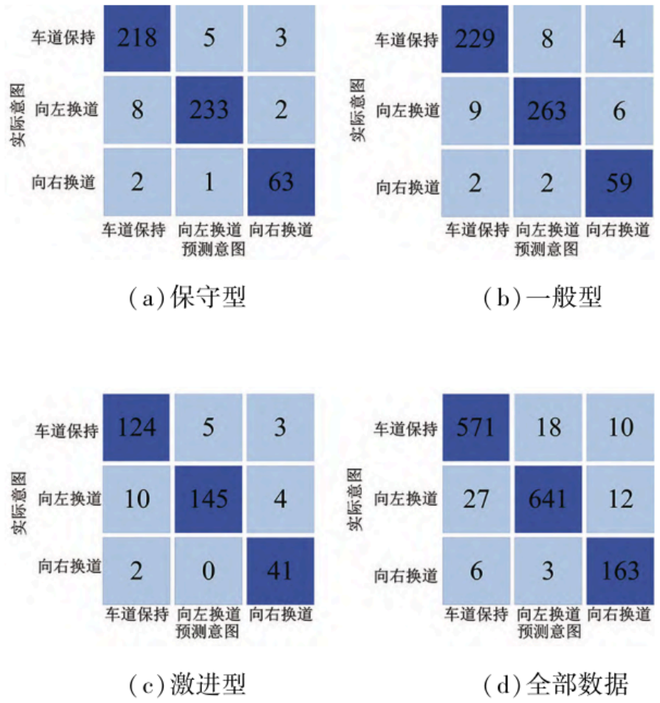
来源：论文第4节、表8、表9；* 表示未划分驾驶风格

不同驾驶风格下的预测结果

保守型准确率最高，激进型相对更难识别；右换道仍需关注。



右换道精确率：一般型85.51%，激进型85.42%。

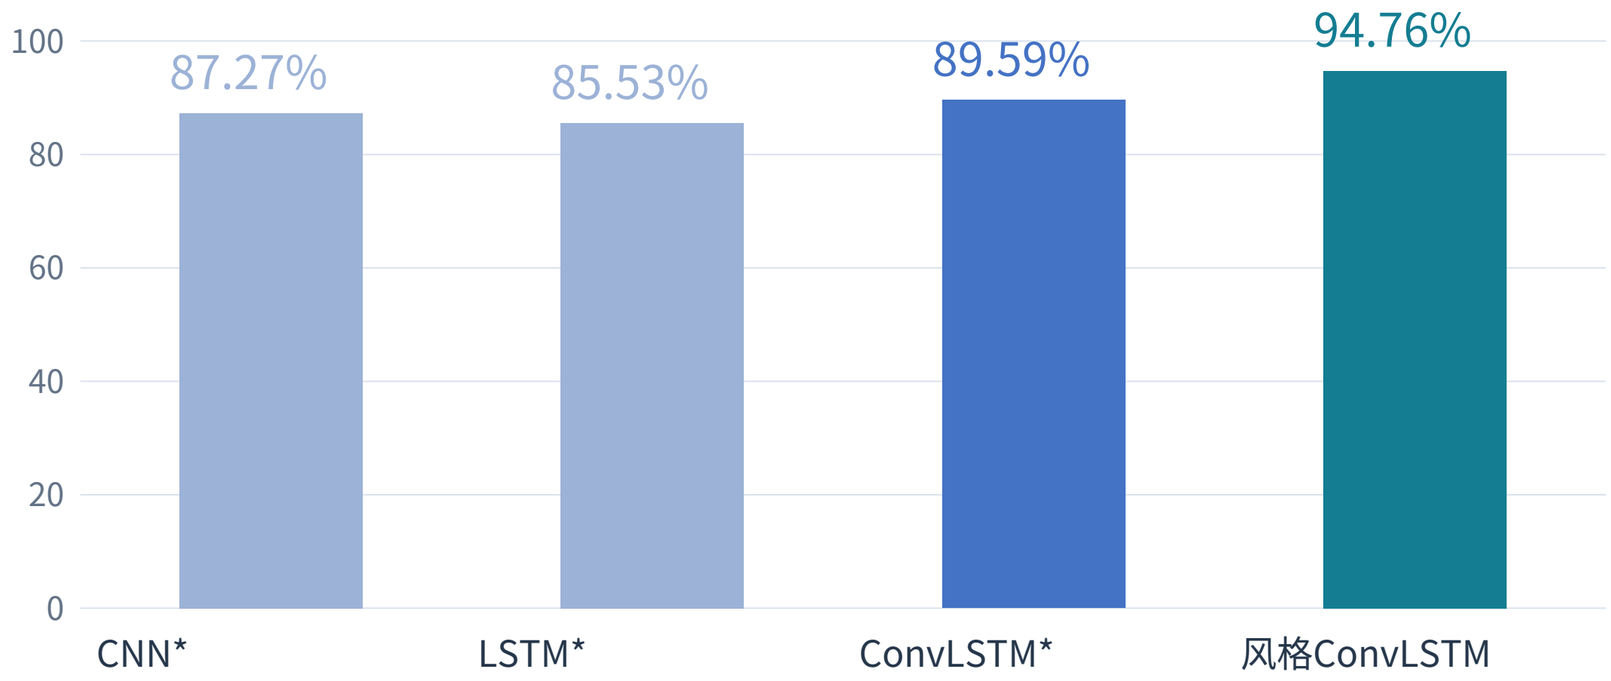


论文图6：三种风格及整体混淆矩阵

来源：论文表8；右图为论文图6（完整）

与基线模型的对比

同一ConvLSTM网络引入风格划分后，准确率提高5.17个百分点。



+5.17

个百分点

94.76% − 89.59%

同模型对照：ConvLSTM* → 考虑风格的ConvLSTM

来源：论文表9（准确率重绘）；* 表示未划分驾驶风格

主要结论与创新点

贡献在于将轨迹形成的风格类别纳入预测流程，并用同模型对照检验收益。

主要结论

1 所用数据上，整体准确率为94.76%。

2 不同风格的预测难度存在差异。

3 部分类别的识别仍有改进空间。

方法贡献

1 统计特征 → 驾驶风格类别。

2 风格分组与ConvLSTM结合。

3 设置有无风格划分的同模型对照。

局限性与研究启示

把意图识别的实验收益，与实时部署和交通流层面的结论分开讨论。

论文已验证的范围

NGSIM历史轨迹上的三类意图识别

按风格分组后的预测表现

与CNN、LSTM、ConvLSTM基线比较

待验证的问题 · 汇报者讨论

网联环境下的实时部署与延迟
预测提前量、跨场景泛化
训练／测试是否按车辆隔离
样本规模、意图类别分布的影响

对自身研究的启示 · 汇报者讨论

驾驶风格如何影响多车切入交互及扰动传播?

来源：论文第5节；待验证问题与研究启示为汇报者讨论